



JAX ANALYTICS



DeflA

R A P P O R T O F F I C I E L

Équipe HEC **Jaune**

JORGE VELEZ



jorge-enrique.velez@hec.ca

XAVIER PÉLADEAU-ASSELIN



xavier.peladeau-asselin@hec.ca

ARNAUD LAVALLÉE



arnaud.lavallee@hec.ca

Table des matières

1. Contexte historique récent	4
1.1 Effets de la COVID	4
1.2 Effets de la guerre Ukraine-Russie	5
1.3 Effets de la guerre commerciale USA-Chine	6
1.4 Effets des marchés financiers	6
2. Politique monétaire de la FED	7
2.1 Évolution des taux directeurs post-2020	7
2.2 Retour progressif vers des politiques moins restrictives (2024)	7
3. Choix des variables	8
3.1 Choix de la variable cible	8
3.2 Choix des variables explicatives	8
3.3 Stationnarisation et test ADF	9
4. Choix de modèles	10
4.1 Méthodologie d'évaluation	10
4.2 Modèles de Référence	11
4.3 Régressions Multiples	12
4.4 Méthodes non-paramétriques	13
4.5 Comparaisons des modèles	15
4.6 Performance sur l'ensemble de test	15
5. Perspectives et recommandations	16
5.1 Analyse des Résultats : Prévisions	16
5.2 Analyse des Impacts Dynamiques via SVAR	16
5.3 Recommandations Stratégiques	18
6. Conclusion	20
Annexe(s)	21
Annexe 1 – Variables Causales Considérées, par Catégorie	21
Annexe 2 – Graphiques d'interprétabilité du TFT	24
Bibliographie	25

Sommaire exécutif

Les taux d'intérêt jouent un rôle central dans les dynamiques financières et économiques, influençant les coûts d'emprunt, les décisions d'investissement et la trajectoire de la croissance économique. Ces fluctuations ne se limitent pas à influencer les marchés financiers, elles redéfinissent également les politiques économiques et les stratégies d'allocation d'actifs. Dans un contexte mondial marqué par une volatilité accrue, des bouleversements géopolitiques majeurs et des ajustements monétaires rapides, anticiper ces variations est devenu essentiel pour minimiser les risques et optimiser les rendements dans tous les secteurs d'activité.

En octobre dernier, la Caisse de dépôt et placement du Québec (CDPQ) a lancé la première édition du **DéfiA**, une initiative visant à explorer le croisement entre la finance et l'intelligence artificielle. Notre équipe, **JAX Analytics**, a été mandatée pour répondre à la question suivante : **Comment anticiper et mesurer l'impact des fluctuations des taux d'intérêt sur le panorama économique global ?**

Ce rapport propose une approche innovante et méthodique pour analyser cette problématique. Dans un premier temps, il examine les transformations rapides et imprévisibles de l'économie mondiale depuis la crise pandémique de 2020. Les injections massives de liquidités, pour contrer les effets de la pandémie, ont laissé place à des politiques monétaires restrictives qui redessinent les dynamiques économiques globales. L'analyse met en lumière les perturbations géopolitiques, les impacts des hausses successives des taux directeurs et les incertitudes croissantes pour les investisseurs.

Dans un second temps, notre équipe détaille les outils et modèles utilisés pour traiter cette problématique. En combinant des approches économétriques éprouvées, comme les modèles VAR et SVAR, et des outils modernes d'apprentissage automatique tels que Temporal Fusion Transformers (TFT) et N-HITS, ce rapport propose des prédictions robustes et des analyses approfondies. Ces modèles permettent non seulement de capturer les interrelations complexes entre les variables économiques, mais aussi de fournir une analyse stratégique sur les impacts des fluctuations des taux sur l'économie globale.

Enfin, les recommandations formulées offrent des pistes concrètes pour optimiser les portefeuilles d'actifs. Les marchés boursiers, soutenus par la reprise des secteurs technologiques et de consommation discrétionnaire, constituent une opportunité clé dans un contexte de détente monétaire. Les placements privés et les infrastructures, quant à eux, tirent parti des coûts d'emprunt réduits pour renforcer leur attractivité. Du côté du revenu fixe, l'accent est mis sur les obligations à longue durée et les titres à haut rendement pour capter des gains en capital et maximiser les rendements ajustés au risque. Ces orientations stratégiques visent à renforcer la résilience et la performance globale des portefeuilles de la CDPQ.

1. Contexte historique récent

1.1 Effets de la COVID

La situation actuelle des marchés résulte des bouleversements majeurs provoqués par la pandémie de COVID-19, qui a marqué un tournant décisif dans l'économie mondiale. En mars 2020, cette crise sanitaire a été déclarée une « pandémie » par l'Organisation mondiale de la santé (OMS), déclenchant une série de perturbations économiques, sociales et politiques dont les effets perdurent encore aujourd'hui. La pandémie a perturbé les chaînes d'approvisionnement mondiales, entraînant des fermetures d'usines en Asie, des retards logistiques et une pénurie de matières premières. Une étude de la Banque mondiale a révélé que 90 % des entreprises ont signalé des interruptions de leur chaîne d'approvisionnement en 2020, mettant en lumière la vulnérabilité de l'économie mondiale face à de tels chocs (World Bank, 2021). Simultanément, les mesures strictes de confinement imposées par de nombreux pays ont provoqué une contraction économique mondiale de 5,2 %, marquant la récession la plus grave depuis plusieurs décennies (World Bank, 2020). Cette situation a plongé des millions de personnes dans la pauvreté, affectant surtout les économies dépendantes du commerce international, du tourisme, et des exportations de matières premières. La chute drastique de la consommation et de l'investissement, couplée à perturbations des chaînes d'approvisionnement, a exacerbé les défis économiques mondiaux. Aux États-Unis, le taux de chômage a atteint un pic de 14,7 % en avril 2020, soit le niveau le plus élevé depuis la Grande Dépression, tandis que l'Organisation internationale du travail (OIT) a estimé que 255 millions d'emplois équivalents temps plein ont été perdus en 2020, représentant une perte de revenus de 3,7 trillions de dollars (International Labour Organization (ILO), 2020).

Face à ces défis, les banques centrales ont déployé des politiques monétaires expansionnistes d'une ampleur inédite pour atténuer les impacts de la récession. Des taux d'intérêt historiquement bas ont été instaurés, et des programmes d'assouplissement quantitatif ont permis l'injection de plus de 9 000 milliards de dollars dans les économies mondiales entre 2020 et 2021 (International Monetary Fund (IMF), 2020). Par exemple, la Réserve fédérale américaine a réduit son taux directeur à une fourchette entre 0 % à 0,25 % (Forbes Advisor, 2023). Ces interventions ont stabilisé temporairement les marchés financiers et apporté des liquidités aux ménages et entreprises touchés. Cependant, elles ont également contribué à l'émergence d'une inflation persistante.

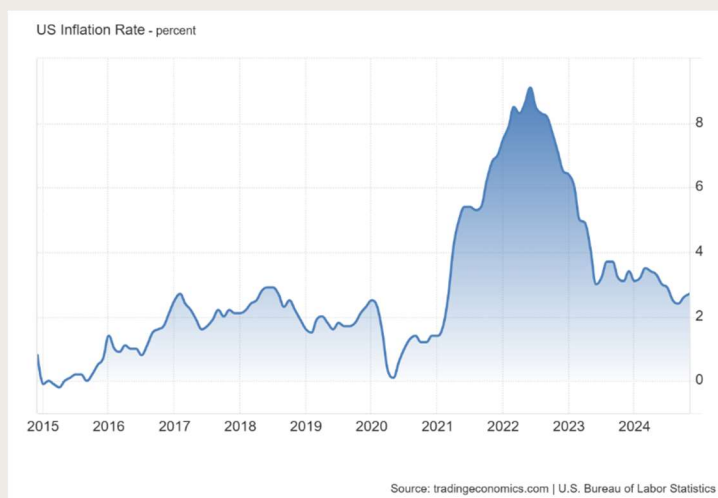


Figure 1

Évolution du taux d'inflation annuel (%) aux États-Unis entre 2015 et 2024, montrant des variations importantes, notamment une forte augmentation en 2022 suivie d'une diminution progressive.

Source:

Trading Economics. (n.d.). *United States Inflation Rate*. Consulté le [15/12/2024], à partir de :

<https://fr.tradingeconomics.com/united-states/inflation-cpi>

En effet, la combinaison de ces politiques expansionnistes avec des facteurs structurels tels que les pénuries de main-d'œuvre et la hausse des coûts de l'énergie a conduit à une inflation mondiale atteignant des niveaux record en 2022. Aux États-Unis, l'inflation a culminé à 9,1 % en juin 2022, son plus haut niveau en 40 ans (U.S. Bureau of Labor Statistics, 2022). Ces dynamiques illustrent l'ampleur des défis économiques engendrés par la pandémie et la complexité des réponses nécessaires pour en atténuer les conséquences.

1.2 Effets de la guerre Ukraine-Russie

En 2022, l'Europe a été profondément marquée par l'invasion de l'Ukraine par la Russie, un événement qui a déclenché l'un des conflits géopolitiques les plus significatifs de ce siècle. Ce conflit a entraîné des répercussions économiques globales, exacerbant les tensions déjà présentes à la suite de la pandémie de COVID-19. En réponse, l'Union européenne, en collaboration avec d'autres nations occidentales, a imposé des sanctions économiques et commerciales strictes à l'encontre de la Russie, visant à isoler le pays sur la scène internationale. Ces mesures comprenaient des restrictions sur les exportations, des interdictions sur l'importation de pétrole et de gaz russes, ainsi que le gel d'actifs appartenant à des entreprises et personnalités russes, totalisant environ 210 milliards d'euros bloqués à la banque centrale russe dans l'Union européenne (Council of the European Union, N/A).

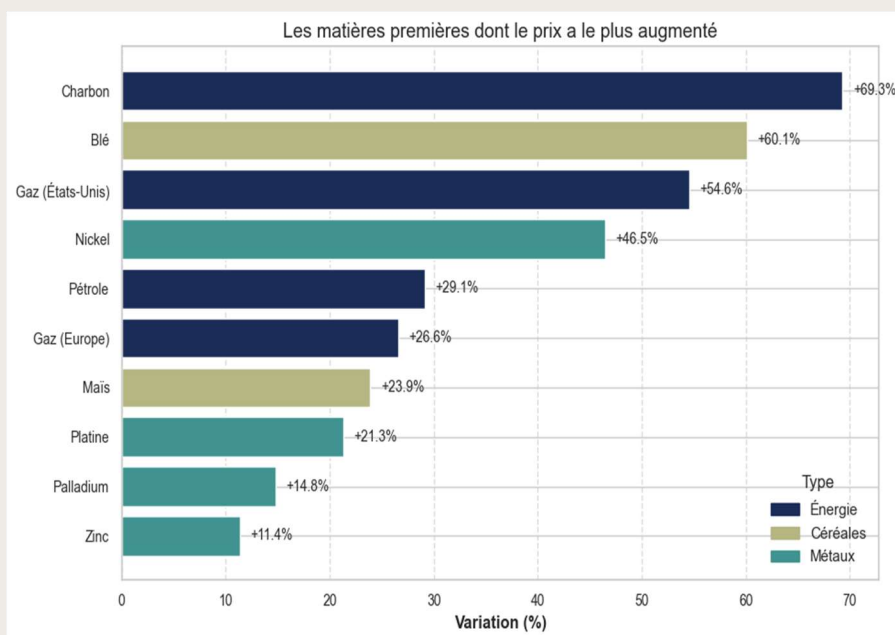


Figure 2

Variation des prix (%) des matières premières telles que le charbon, le blé, et le gaz, par rapport à leur moyenne de janvier 2022. (*Graphique fais sur python)

Source:

Statista. (n.d.). *Les matières premières dont le prix a le plus augmenté depuis le début de la guerre en Ukraine*. Consulté le [17/12/2024], à partir de <https://fr.statista.com/infographie/27599/mati-eres-premieres-dont-le-prix-a-le-plus-augmente-depuis-le-debut-guerre-ukraine-variation-des-prix-energie-cereales-metaux/>

Ces sanctions ont eu des impacts significatifs, particulièrement en Europe, où de nombreux États membres dépendent fortement des ressources énergétiques russes. Avant leur mise en place, près de la moitié des exportations totales de pétrole de la Russie étaient destinées à l'Union européenne, représentant une valeur de 71 milliards d'euros en 2021, dont 48 milliards pour le pétrole brut et 23 milliards pour les produits pétroliers raffinés. La décision de l'Union européenne de couvrir 90 % des importations de pétrole russe a engendré une hausse spectaculaire des prix de l'énergie, avec le baril de pétrole brut Brent atteignant plus de 130 dollars en mars 2022, un sommet observé pour la première fois depuis 14 ans (Council of the European Union, N/A) (Country Economy, 2022). Cette augmentation des coûts énergétiques a directement influencé les coûts de production et les prix à la consommation, accentuant, encore une fois, une inflation déjà en hausse.

En parallèle, l'Ukraine, souvent qualifiée de « grenier à blé de l'Europe », a vu sa production agricole gravement affectée par le conflit. Avant l'invasion, le pays représentait environ 10 % des exportations mondiales de blé et 15 % de celles de maïs (Zulauf, 2023). La guerre a perturbé de manière significative les exportations et la production agricole, avec des ports bloqués et des champs détruits. Cette situation a entraîné une hausse historique des prix du blé, augmentant de 60 % en 2022, ce qui a particulièrement touché les pays en développement fortement dépendants des importations alimentaires (Clark, 2022). La combinaison de la crise énergétique et de la crise alimentaire a amplifié cette inflation mondiale, révélant les vulnérabilités des interdépendances dans les secteurs clés de l'énergie et de l'alimentation.



1.3 Effets de la guerre commerciale USA-Chine

La guerre commerciale entre les États-Unis et la Chine, initiée sous l'administration de Donald Trump, a marqué un tournant décisif dans les relations économiques entre ces deux puissances mondiales, engendrant des perturbations économiques majeures. En septembre 2018, les États-Unis ont imposé des droits de douane sur 200 milliards de dollars de produits chinois, avec un taux initial de 10 %, porté à 25 % en mai 2019 (Britt, 2021). En réponse, la Chine a instauré des tarifs douaniers sur 60 milliards de dollars de produits américains, ciblant notamment des secteurs stratégiques comme l'agriculture (Britt, 2021). En décembre 2019, une tentative d'apaisement a été initiée avec la signature de l'accord "Phase 1". Cet accord prévoyait un engagement de la Chine à augmenter ses achats de produits agricoles américains, tels que le soja et le porc, tandis que les États-Unis suspendaient l'imposition de nouveaux tarifs. Malgré cet effort, les droits de douane sur environ 360 milliards de dollars d'importations chinoises ont été maintenus, continuant de peser lourdement sur les entreprises et consommateurs des deux pays (Britt, 2021). Les coûts accrus des importations ont contribué à des pressions inflationnistes significatives, les entreprises nord-américaines absorbant ces surcoûts ou les répercutant sur leurs clients.

Au-delà des échanges commerciaux, la rivalité s'est intensifiée dans le domaine technologique, avec un accent particulier sur les technologies critiques ayant des applications militaires. Les États-Unis ont imposé des restrictions visant à limiter l'accès de la Chine à des semi-conducteurs avancés et à d'autres technologies de pointe. En 2024, le Département du Commerce américain a renforcé ces mesures, élargissant les contrôles sur 24 types d'équipements de fabrication de semi-conducteurs et inscrivant 140 entités chinoises sur une liste de restrictions (Bureau of Industry and Security, 2024). Ces politiques visaient à entraver la capacité de la Chine à développer des technologies nécessaires à ses ambitions militaires. En réponse, la Chine a intensifié ses efforts pour développer des alternatives locales, réduisant ainsi sa dépendance technologique vis-à-vis des États-Unis. Cette guerre commerciale a exacerbé des tensions économiques et géopolitiques mondiales. Aux États-Unis, l'augmentation des prix des biens importés a directement affecté les consommateurs, tandis que les perturbations des chaînes d'approvisionnement et les tensions technologiques ont accru la volatilité des marchés financiers, alimentant un climat d'incertitude global.

1.4 Effets des marchés financiers

Au cours des dernières années, les marchés boursiers ont connu des fluctuations marquées, oscillant entre des pertes significatives et des rebonds spectaculaires. En 2022, Le S&P 500 a reculé de 19,4 %, le Nasdaq Composite, exposé aux valeurs technologiques, a chuté de 33,1 %, tandis que le Dow Jones Industrial Average a limité ses pertes à 8,8 %, illustrant sa résilience relative (Trends, 2023).

Malgré ces pertes, les marchés ont entamé une reprise spectaculaire en 2023 et 2024, soutenus par des signes de détente monétaire et des perspectives économiques plus favorables. Le Nasdaq, moteur de cette reprise, a été porté par l'essor des entreprises technologiques, en particulier celles liées à l'intelligence artificielle et à la transformation numérique. Le S&P 500 a également atteint de nouveaux sommets historiques, soulignant la résilience des entreprises face à un environnement économique en constante évolution (Wisniewski, 2024).

Cette période a également été marquée par une forte volatilité, comme en témoigne l'indice VIX, qui a fréquemment dépassé 30 en 2022, reflétant une nervosité élevée des investisseurs. Bien que le VIX ait diminué en 2023 et 2024, il est resté au-dessus de ses niveaux pré-pandémiques, illustrant les ajustements continus des marchés aux incertitudes macroéconomiques et géopolitiques (MacroTrends, 2024).



2. Politique monétaire de la FED

2.1 Évolution des taux directeurs post-2020

Confrontées à une inflation persistante, la Réserve fédérale américaine (FED) a changé de cap en 2022, initiant un cycle marqué de resserrement monétaire pour maîtriser la hausse des prix. Dès cette année, l'institution a relevé les taux directeurs à un rythme sans précédent. La FED a porté son taux des fonds fédéraux à une fourchette entre 5 % à 5,25 % en mai 2023, accumulant une hausse de 4,75 points de pourcentage en un peu plus d'un an (Forbes Advisor, 2023). Ces décisions ont entraîné des répercussions économiques immédiates, modifiant profondément les dynamiques financières et économiques. Les hausses rapides des taux ont entraîné une augmentation significative des coûts d'emprunt pour les ménages et les entreprises, provoquant un ralentissement de la consommation et de l'investissement. Aux États-Unis, le marché immobilier a été particulièrement touché, enregistrant une baisse de 20 % des ventes de maisons existantes en 2022 (Dua, 2022). Ces circonstances rappellent les prémices du crash financier mondial de 2008, ravivant les craintes d'une crise systémique dans les économies nord-américaines. Si ces politiques monétaires restrictives ont permis de ralentir l'inflation, elles ont également entraîné un ralentissement de l'activité économique, obligeant les décideurs à trouver un équilibre délicat entre la maîtrise des prix et le soutien à la croissance (Young, 2022).

2.2 Retour progressif vers des politiques moins restrictives (2024)

En 2024, les grandes banques centrales, notamment la Réserve fédérale américaine (FED), a amorcé une transition progressive vers une politique monétaire moins restrictive. Cette évolution a été motivée par un ralentissement de l'inflation, qui, bien qu'encore au-dessus des objectifs, a montré des signes d'atténuation notables par rapport aux sommets atteints en 2022. Aux États-Unis, l'inflation annuelle est tombée à environ 3,7 % en octobre 2024, se rapprochant de l'objectif de 2 % fixé par la FED (U.S. Bureau of Labor Statistics, 2022). Aux États-Unis, le taux des fonds fédéraux a été abaissé à une fourchette entre 4,5 % à 4,75 % (Forbes Advisor, 2023). Ces ajustements ont offert un certain répit aux ménages et aux entreprises, notamment pour les crédits hypothécaires et les investissements. Toutefois, les banques centrales ont maintenu un discours prudent, soulignant la nécessité d'adapter leurs politiques en fonction des données économiques à venir pour éviter un éventuel retour de l'inflation. Cette transition monétaire s'inscrit dans un contexte politique complexe. Aux États-Unis, l'élection présidentielle de 2024, marquée par le retour de Donald Trump sur la scène politique, a ajouté une nouvelle dimension d'incertitude économique et géopolitique. Les politiques économiques imprévisibles et la rhétorique protectionniste potentielles associées à Trump rappellent les tensions commerciales de son précédent mandat (Goldman Sachs, 2024). Ces facteurs ont incité les marchés financiers à adopter une posture prudente, anticipant des changements possibles dans les relations commerciales internationales et les politiques fiscales. Cette combinaison de facteurs économiques et politiques a contribué à renforcer la volatilité sur les marchés financiers, où les investisseurs restent attentifs aux signaux des banques centrales et aux développements politiques.




Figure 3

Évolution du taux effectif des fonds fédéraux américains entre 2018 et 2024.

Source:

Data du concours « data_concours ».
(*Graphique fais sur python)



3. Choix des variables

3.1 Choix de la variable cible

Dans le cadre de notre mandat, notre équipe a sélectionné le taux à 10 ans des obligations du trésor du gouvernement américain comme variable cible, en raison de son importance stratégique en tant qu'indicateur des taux d'intérêt à long terme. Cette décision repose sur plusieurs arguments clés. Tout d'abord, les taux des obligations américaines servent de référence pour l'économie mondiale, établissant une base essentielle pour l'évaluation des coûts d'emprunt. Par ailleurs, la maturité de 10 ans offre un équilibre optimal, réduisant l'impact des fluctuations quotidiennes causées par le bruit du marché tout en capturant des dynamiques économiques à long terme. De plus, nous avons choisi de ne pas retenir la variable « FFED », car elle est déterminée par le Federal Open Market Committee (FOMC), dont les décisions sont influencées par des considérations économiques complexes et des débats internes entre ses membres. En outre, cette variable est très difficile à prédire.

Notre variable cible constitue également une synthèse des dynamiques fondamentales des marchés financiers. Elle reflète l'évolution des principales maturités des obligations américaines, intègre les anticipations de politique monétaire de la Réserve fédérale (FED) et capte les attentes en matière d'inflation et de croissance économique. Une prévision précise de cette variable permettrait non seulement de guider les choix stratégiques entre revenus fixes et actions, mais également d'optimiser les allocations d'actifs en fonction des anticipations de taux, de l'environnement économique et du sentiment du marché, tout en maîtrisant efficacement les risques associés. Bien que notre analyse soit spécifiquement limitée aux États-Unis pour des raisons de simplicité et de faisabilité, les conclusions méthodologiques de cet exercice pourraient être adaptées pour prédire les autres taux des obligations du trésor du gouvernement américain (différentes maturités), ainsi que les taux d'intérêt dans d'autres pays.

3.2 Choix des variables explicatives

Notre équipe d'analystes a reçu de la part de la Caisse de dépôt et placement du Québec (CDPQ) une vaste base de données contenant de nombreuses variables économiques pertinentes pour répondre aux exigences du mandat. Bien que ces variables semblaient suffisantes pour accomplir la tâche, l'équipe a décidé d'élargir ses sources afin d'augmenter le potentiel explicatif des modèles. Ainsi, près de 82 variables supplémentaires ont été collectées auprès de la Federal Reserve Bank of St. Louis, ainsi que deux indicateurs spécifiques provenant de la Federal Reserve Bank of San Francisco (Federal Reserve Bank of San Francisco, 2024) (Federal Bank of St. Louis, 2024). Les deux indicateurs de la Federal Reserve Bank of San Francisco ont été retenus pour leur pertinence et la rigueur des travaux qui sous-tendent leur développement. Parmi eux, la variable « NEWS_SENTIMENT » se distingue. Cet indice, développé à l'aide de techniques avancées de traitement automatique du langage naturel (NLP), analyse un large ensemble d'articles de presse afin d'en extraire une tonalité générale. Ce processus repose sur l'identification et la pondération des mots jugés positifs ou négatifs. Les articles, issus de diverses sources, sont traités quotidiennement pour générer un score reflétant l'humeur ou le climat médiatique du moment (Federal Reserve Bank of San Francisco, 2024). Ce baromètre de sentiment constitue un outil précieux pour capturer les signaux véhiculés par la presse.

Toutes les variables collectées ont été soigneusement sélectionnées en fonction de leur fiabilité et de leur pertinence économique, avec pour objectif de maximiser la robustesse des modèles et la qualité des analyses. Avec un total de près de 200 variables, notre équipe a d'abord effectué un tri méthodique en les regroupant dans des catégories telles que : Chômage, Inflation, PIB, etc. Une fois ce tri effectué, l'équipe a choisi les 7 variables les plus pertinentes par catégorie, d'après l'expertise des analystes. L'équipe a par la suite fait appel à l'utilisation du test de Granger, qui s'est révélée cruciale pour identifier les variables les plus causales. Le test de Granger est un test statistique qui évalue dans quelle mesure la connaissance des valeurs passées d'une variable X peut améliorer la prévision d'une variable Y, comparativement à l'utilisation de seulement les valeurs passées de Y. Cette méthode a permis de révéler les variables ayant un véritable pouvoir prédictif, influençant significativement les fluctuations d'une autre variable (Jianjun Zhang, 2023). Grâce à cette approche, notre équipe a réduit le nombre de variables à 17, jugées causales (**Voir Annexe 1**). Bien que la sélection ait permis de



réduire considérablement le nombre de variables, le total restant crée un ratio observations/variables trop élevé, qui peut produire un modèle non généralisable, peu fiable et difficile à interpréter. Pour affiner davantage cette sélection, l'équipe a appliqué la régression de Lasso. Lasso impose une pénalité sur la somme des valeurs absolues des coefficients d'un modèle, ce qui réduit à zéro les coefficients des variables les moins pertinentes (Great Learning Editorial Team, 2024). Cette technique ne conserve que les variables ayant une contribution significative, simplifiant ainsi le modèle tout en maintenant sa robustesse. Cette approche a permis de finaliser la sélection des variables les plus explicatives, assurant un équilibre optimal entre précision des prévisions et simplicité du modèle.

3.3 Stationnarisation et test ADF

Dans les modèles de prévision des séries temporelles, la stationnarisation des variables est cruciale. Une série stationnaire conserve des propriétés constantes dans le temps, comme la moyenne, la variance et l'autocorrélation, ce qui est fondamental pour la plupart des techniques de modélisation. En éliminant les tendances, les variations saisonnières et les chocs structurels, elle simplifie l'analyse et renforce la robustesse des modèles, permettant de produire des prévisions plus fiables et cohérentes. La stationnarité est également essentielle pour garantir la validité des tests statistiques et des diagnostics de modélisation, comme l'analyse des résidus ou l'identification des processus autorégressifs. Elle assure la précision des intervalles de confiance et des conclusions basées sur les prévisions. En revanche, une série non stationnaire peut entraîner des biais, des résultats incorrects et des décisions mal informées. Pour ces raisons, notre équipe a décidé de stationnariser les variables. Une série non stationnaire peut présenter différents types de tendances : déterministe (évolution régulière et prévisible), stochastique (évolution aléatoire due à une racine unitaire), saisonnière (comportement périodique répété) ou une variance non constante (hétéroscédasticité) avec une moyenne stable. Bien sûr, cette liste n'est pas exclusive, la série pourrait aussi avoir une tendance non linéaire, un changement de régime et bien d'autres (Ondo, 2002). Pour stationnariser nos variables, nous avons utilisé le test ADF (Augmented Dickey-Fuller), un outil statistique permettant de vérifier si une série temporelle est stationnaire. Ce test est une extension du test Dickey-Fuller, conçu pour gérer les séries présentant de l'autocorrélation. Il repose sur une hypothèse nulle affirmant que la série possède une racine unitaire, donc qu'elle est non stationnaire. Le test ADF s'effectue en estimant l'une des trois régressions suivantes :

	Test	Quand l'utiliser
(I) $\Delta y_t = \gamma y_{t-1} + \sum_{i=1}^p \phi_i \Delta y_{t-i} + \varepsilon_t$	$H_0 : \gamma = 0$ $H_1 : \gamma < 0$	y_t a une moyenne nulle
(II) $\Delta y_t = \delta + \gamma y_{t-1} + \sum_{i=1}^p \phi_i \Delta y_{t-i} + \varepsilon_t$	$H_0 : \gamma = 0$ $H_1 : \gamma < 0$	y_t a une moyenne constante non nulle
(III) $\Delta y_t = \delta + \alpha t + \gamma y_{t-1} + \sum_{i=1}^p \phi_i \Delta y_{t-i} + \varepsilon_t$	$H_0 : \gamma = 0$ $H_1 : \gamma < 0$	y_t a une tendance déterministe linéaire

Figure 4
Formules pour les tests ADF et quand les utiliser

Source: Cacciatore, M. (2024). Formule du test ADF. Dans MATH60837.A2024 - Économétrie des séries temporelles. HEC Montréal.

L'équipe a commencé par classer chaque variable dans l'une des trois catégories en analysant visuellement les graphiques des variables d'intérêt sur la période d'échantillon. Par la suite, les tests ADF appropriés ont été appliqués à chaque variable. L'implémentation qu'on a utilisé de ces tests ADF, qui déterminent automatiquement le nombre de lags optimal p à l'aide du critère AIC (critère d'information d'Akaike), ont produit des statistiques ADF. L'AIC est une mesure utilisée pour évaluer la qualité relative de différents modèles statistiques pour une même série de données. Ce critère prend en compte la précision du modèle et sa complexité. Pour évaluer si l'hypothèse nulle de racine unitaire (non-stationnarité) pouvait être rejetée, nous avons comparé les statistiques ADF aux valeurs critiques de Dickey-Fuller. Si la statistique ADF était inférieure à la valeur critique, nous avons rejeté l'hypothèse nulle. Cette évaluation a été effectuée avec un niveau de signification de 1 %. Les variables pour lesquelles nous avons rejeté l'hypothèse nulle ont été considérées comme stationnaires, tandis que celles pour lesquelles l'hypothèse nulle n'a pas été rejetée ont été classées comme non stationnaires. Pour les séries non stationnaires, nous avons effectué une différenciation de premier ordre, puis répété les étapes : analyse visuelle des séries différenciées, application du test ADF et comparaison des résultats avec les valeurs critiques de Dickey-Fuller. Toutes les séries



différenciées se sont avérées stationnaires, confirmant que ces séries non différenciées étaient intégrées d'ordre 1 ($I(1)$) et elles sont donc stationnaire une fois différenciées. Ainsi, toutes les séries temporelles de nos variables ont été stationnarisées, ce qui nous permet de poursuivre notre analyse. Le test ADF a tout de même des limites, car les tests de racines unitaires éprouvent des difficultés à distinguer les processus stationnaires fortement persistants des processus non stationnaires, surtout dans des petits échantillons. Le test pourrait identifier que les séries sont non stationnaires, mais en réalité, elles seraient stationnaires, mais persistantes surtout dans de petits échantillons. Le test KPSS (ce test inverse les hypothèses nulle et alternative) aurait pu être utilisé pour ajouter de la robustesse (Cacciatore 2024).

4. Choix de modèles

L'utilisation de prévisions relatives à la valeur future des taux d'intérêt pour un mois donné constitue un outil stratégique essentiel pour éclairer les décisions de la Caisse. De manière générale, ces prévisions peuvent être élaborées à partir de trois catégories de méthodes distinctes, soient :

- 1) **Extrapolation** : Ces méthodes reposent exclusivement sur l'utilisation des valeurs historiques d'une variable pour prédire ces valeurs futures.
- 2) **Régressions multiples**: Ces modèles combinent les valeurs historiques des taux d'intérêt avec d'autres variables explicatives afin de générer des prévisions. Une limitation importante de ces modèles est que la nature de la relation entre deux variables doit être spécifiée, et ne peut pas donc pas être détectée dynamiquement.
- 3) **Méthodes non-paramétriques** : Ces méthodes permettent aux modèles de modéliser des relations complexes entre la variable cible, comme les taux d'intérêt, et les variables explicatives. Grâce à leur flexibilité et à leur puissance, elles incluent des techniques d'apprentissage profond, qui sous-tendent les avancées récentes dans les modèles de langage et d'autres applications de l'intelligence artificielle.

Dans le cadre de notre mandat, nous avons identifié plusieurs méthodes potentiellement pertinentes pour la prévision du taux des bons du Trésor émis par le gouvernement américain avec une maturité constante de 10 ans. Afin de déterminer si l'effort supplémentaire associé à l'usage de modèles plus complexes en valait la peine, les performances de deux modèles d'extrapolation, deux régressions multiples et deux modèles non-paramétriques ont été compilées et sont présentées dans cette section.

4.1 Méthodologie d'évaluation

Afin d'évaluer l'habileté de chaque modèle à prédire les valeurs futures du taux d'intérêt de manière équitable, une méthodologie d'évaluation stricte nommée « évaluation sur une origine de prévision glissante » a été utilisée (Hyndman, 2021). Cette approche mesure la performance hypothétique qu'aurait obtenue chaque modèle s'il avait été utilisé pendant la période couverte par notre ensemble de validation, que nous définirons dans la section suivante. Elle consiste à réentraîner le modèle avec les données disponibles avant chaque prévision, pour chaque mois de la période d'évaluation à définir.

Tous les modèles considérés possèdent la capacité de produire des prévisions pour un nombre arbitraire de périodes dans le futur. La différence de temps entre le moment où une prévision est produite et le temps auquel elle s'applique, est appelée *l'horizon de prévision*. Afin de prendre en compte les différents scénarios dans lesquels la Caisse de dépôt et placement du Québec (CDPQ) pourrait utiliser les modèles, ceux-ci ont été évalués pour 4 horizons différents. Ceux-ci sont : 1 mois, 3 mois, 1 an et 3 ans.



4.1.1 Définition des sous-ensembles

Les périodes d'entraînement, de validation et de test, qui seront respectivement utilisées pour entraîner les modèles, pour comparer les modèles entre eux et pour quantifier la performance espérée du modèle final ont été définis comme suit :

- Entraînement : février 1980 à décembre 2015
- Validation : janvier 2016 à août 2023
- Test : septembre 2023 à août 2024

4.1.2 Mesures d'erreurs

Pour chaque modèle et horizon considéré, les erreurs moyennes associées aux prévisions faites sur la période de validation ont été compilées. Deux mesures d'évaluation seront présentées, soient :

- Erreur Absolue Moyenne (Mean Absolute Error – MAE) : L'erreur absolue moyenne quantifie l'écart absolu entre le taux prédit et le taux observé.
- Pourcentage d'erreur absolue moyen (Mean Absolute Percent Error – MAPE) : Le pourcentage d'erreur absolue moyen quantifie une notion similaire, mais est relatif au taux observé. Par exemple, une prévision de 1,2% lors d'un mois où la valeur réelle est de 1% obtiendrait un pourcentage d'erreur de 20%.

4.2 Modèles de Référence

4.2.1 Modèle AR(p)

Nous avons opté pour l'utilisation d'un modèles AR (Autorégressif) comme premier modèle de référence. L'AR est une méthode statistique qui permet de modéliser et de prédire une série temporelle en utilisant ses propres valeurs passées. Le modèle AR(p) est une forme particulière de régression qui repose sur le principe que la valeur de la variable dépendante est expliquée par ses propres p valeurs passées (lags) plutôt que par des variables indépendantes externes. Le nombre de valeurs passées (lag) est déterminé avec le critère d'AIC sur les données d'entraînement. L'AIC nous indique que le nombre de valeurs passées optimal est de 12, donc nous utilisons un AR (12) (Noble, 2024). Ensuite nous ajustons le modèle avec les valeurs d'entraînement du rendement 10 ans pour trouver les coefficients de chacune de ces 12 valeurs passées et la constante pour pouvoir faire des prédictions avec une équation de la sorte avec $p = 12$.

$$y_t = \delta + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + u_t$$

Figure 5

Formule pour un AR(p) de base

Source: Cacciatore, M. (2024). Formule AR(p). Dans MATH60837.A2024 - Économétrie des séries temporelles. HEC Montréal.

4.2.2 Modèle Naïf

Pour notre second modèle de référence, nous avons opté pour l'utilisation d'un modèle Naïf. Pour prédire le taux d'intérêt a un moment t nous utilisons seulement le taux d'intérêt au temps $t - 1$. Ce qui signifie que la valeur de taux d'intérêt ce mois-ci est exactement la valeur du taux d'intérêt le mois passé et ainsi de suite. Nous utilisons cette méthode, car nous voulons simplement un modèle de base pour pouvoir comparer des modèles plus complexes futures. Nous utilisons aussi plusieurs horizons de prédiction, donc si l'horizon est de 2 mois; le taux d'intérêt pour le 2 prochains mois (temps $t+1$ et $t+2$) sera le taux d'intérêt de ce mois-ci (temps t). Même chose pour un horizon de 3 mois; le taux d'intérêt pour le 3 prochains mois sera le taux d'intérêt pour ce moi ci et ainsi de suite pour différent horizon.



4.3 Régressions Multiples

4.3.1 VAR

Après de nombreuses recherches et analyses, notre équipe a opté pour un modèle VAR (Vectoriel Autorégressif). Ce modèle multivarié est particulièrement adapté pour analyser les interactions dynamiques entre des séries temporelles stationnaires. Contrairement aux modèles univariés, il prend en compte les influences croisées entre les variables, offrant ainsi une vision plus complète des relations entre elles. Le VAR repose sur l'idée que les séries temporelles interagissent de manière rétroactive et dynamique. Il s'agit d'un modèle de régression multivariée qui inclut les valeurs passées (lags) des variables et réalise plusieurs régressions simultanément, une pour chaque série temporelle. En d'autres termes, la valeur de chaque variable à un instant donné est une combinaison linéaire des valeurs passées de toutes les variables du modèle, y compris elle-même. Cette approche permet de capturer à la fois les interactions croisées et les évolutions historiques propres à chaque série, ce qui en fait un outil puissant pour notre analyse. Nous avons donc 9 équations (qui est le nombre de variables) à estimer. Nous aurons donc une prédiction pour chaque variable qui comprend les autres variables et elle-même. Nous ajustons le modèle VAR sur les données d'entraînement et nous trouvons les constantes et les coefficients pour chaque valeur passée de toutes les variables et pour chaque équation. Nous pouvons donc faire nos prédictions pour chaque horizon en utilisant les vraies valeurs passées de chaque variable et les valeurs prédites pour chacune des variables dépendamment de l'horizon. Ceci est de la prévision récursive (FasterCapital, 2024).

$$Y_t = \Theta + \Phi_1 Y_{t-1} + \dots + \Phi_p Y_p + \varepsilon_t,$$

– Φ_1, \dots, Φ_p sont des matrices $(N \times N)$ contenant les coefficients autorégressifs · – Θ et ε_t sont des vecteurs $(N \times 1)$:

$$\Phi_i = \begin{bmatrix} \phi_{11}^i & \dots & \phi_{1N}^i \\ \dots & \dots & \dots \\ \phi_{N1}^i & \dots & \phi_{NN}^i \end{bmatrix}.$$

$$\Theta = \begin{bmatrix} \delta_{1t} \\ \delta_{2t} \\ \dots \\ \delta_{Nt} \end{bmatrix}, \varepsilon_t = \begin{bmatrix} \varepsilon_{1t} \\ \varepsilon_{2t} \\ \dots \\ \varepsilon_{Nt} \end{bmatrix};$$

Figure 6

Formule pour un VAR(p) de base

Source: Cacciatore, M. (2024). Formule pour un VAR(p). Dans MATH60837.A2024 - Économétrie des séries temporelles. HEC Montréal.

4.3.2 Lasso

La régression Lasso est une régression linéaire à laquelle est ajouté un terme de pénalisation qui encourage le modèle à utiliser moins de variables. Tel que mentionné précédemment (**Voir Section 3**), seules les variables retenues par le modèle Lasso ont été utilisées pour l'entraînement des modèles subséquents. La précision des prévisions produites par celui-ci est présentée plus loin, conjointement avec celles des autres modèles.

4.3.3 Limites

Bien entendu les modèles VAR et Lasso ont des limites. Puisque nous différencions certaines variables pour les rendre stationnaires, il pourrait être judicieux de vérifier si les variables qui sont différenciées sont aussi cointégrées pour un prochain mandat. Sans regarder la cointégration nous aurions pu être en présence d'un modèle mal spécifié. Nous pourrions utiliser le test de Johansen, qui détermine le nombre de relations de cointégrations (le rang de la matrice de cointégration). Pour le VAR, si les variables ont de la cointégration nous pourrions utiliser un VECM (un modèle Vectoriel à Correction d'Erreur qui est une extension du modèle VAR qui prend en compte les relations de cointégration entre les variables) ce qui aurait pu apporter de meilleurs résultats (Voir Section 5 : résultat de VAR) (Chen, 2022). Puisque pour le SVAR la cointégration n'a pas d'importance (nous couvrirons ceci plus loin), nous n'avons pas poussé plus loin sur ce sujet.



4.4 Méthodes non-paramétriques

Les méthodes non-paramétriques, qui incluent notamment les modèles d'apprentissage profond tels que ChatGPT, constituent un domaine de recherche en pleine expansion. La littérature scientifique récente met en lumière une diversité impressionnante d'approches pour la modélisation des séries temporelles. Dans ce contexte, notre équipe a effectué une revue des travaux récents afin d'identifier les modèles de pointe les plus adaptés à la prévision des taux d'intérêt (John A. Miller, 2024). À l'issue de cet exercice, deux modèles ont été sélectionnés et appliqués à notre analyse : le Temporal Fusion Transformer (TFT) et le Neural Hierarchical Interpolation for Time Series Forecasting (N-HITS). Contrairement aux modèles présentés jusqu'à présent, ces modèles possèdent la capacité de produire des intervalles de prévision pouvant être utilisés comme indicateur du niveau de confiance du modèle, ce qui est un avantage important dans un contexte financier. Les caractéristiques principales de ces modèles sont décrites dans cette section. Par la suite, deux approches émergentes, à savoir l'utilisation de modèles de fondation et de grands modèles de langage, sont proposées comme pistes intéressantes pour de futures recherches.

4.4.1 Temporal Fusion Transformers (TFT)

Le Temporal Fusion Transformer (TFT) est conçu pour la prévision multi-horizon de séries temporelles complexes, comme les taux d'intérêt des obligations gouvernementales. Son architecture intègre des mécanismes tels que la sélection des variables pertinentes et des couches d'attention auto-interprétable, qui permettent de capturer les dépendances temporelles à court et long terme. Ces fonctionnalités le rendent particulièrement utile en finance, où il est essentiel de comprendre comment divers facteurs, tels que les données économiques historiques ou des événements futurs connus, influencent les prévisions. Le TFT se distingue par sa capacité à identifier les variables les plus significatives, à détecter les motifs temporels persistants et à mettre en évidence les événements clés. Cette approche offre des insights exploitables qui peuvent guider efficacement les décideurs financiers dans un environnement dynamique et incertain (Bryan Lim, 2020). Certains des graphiques d'interprétabilité produits par le modèle sont inclus dans l'annexe 2 du présent document, à titre indicatif. Ils indiquent notamment l'importance relative de chaque variable explicative pour la production d'une prévision.

4.4.2 Neural Hierarchical Interpolation for Time Series Forecasting (N-HITS)

L'architecture du modèle N-HITS (Neural Hierarchical Interpolation for Time Series Forecasting) est conçue pour répondre aux besoins de prévision des séries temporelles à long terme, telles que les taux d'intérêt des obligations gouvernementales. Elle repose sur une interpolation hiérarchique et un échantillonnage multi-échelle, qui décomposent les




Figure 7

Prévisions de N-HITS avec intervalles de prévision (mauve) et valeurs réelles (noir) pour chacun des 4 horizons considérés pour l'évaluation

signaux en différentes composantes fréquentielles. Chaque bloc du modèle se spécialise dans une bande de fréquence particulière, ce qui améliore à la fois la précision des prévisions et l'efficacité computationnelle, tout en réduisant les coûts de calcul. Cette caractéristique implique que le temps d'entraînement du N-HITS est environ 50x plus rapide que celui du



TFT. Ceci permet aussi au modèle de produire des prévisions pour des horizons lointains sans besoin computationnel important. (Cristian Challu, 2022).

4.4.3 Modèles de fondation (Foundation models)

Des modèles généralistes, capables d'être appliqués à de nouvelles séries temporelles sans nécessiter un entraînement spécifique sur celles-ci, ont récemment été introduits par la communauté de recherche en IA. Parmi ces modèles, on trouve Chronos et TimesFM, développés respectivement par des équipes chez Amazon et Google.

Bien que l'idée d'exploiter l'information contenue dans d'autres séries temporelles pour entraîner un modèle puisse sembler prometteuse, cette approche n'a pas été retenue dans notre étude pour deux raisons principales. Tout d'abord, ces modèles ne permettent pas l'intégration complète de variables explicatives additionnelles. Même si des variables explicatives peuvent être fournies, elles ne sont prises en compte que dans une étape ultérieure, sous la forme d'une combinaison linéaire des prévisions et de ces variables. Cela limite leur influence à des effets strictement linéaires, réduisant ainsi leur pertinence pour des analyses plus complexes (Abdul Fatir Ansari, 2024) .

Ensuite, nous estimons que la nature chaotique et volatile de l'évolution du taux mensuel réduit l'utilité d'intégrer des dynamiques propres à des séries temporelles très différentes, telles que la consommation énergétique d'une région ou les ventes historiques de produits saisonniers. Ces informations extérieures, bien que potentiellement enrichissantes dans d'autres contextes, auraient vraisemblablement un impact négligeable sur la précision des prévisions de taux futurs (Abhimanyu Das, 2024).

4.4.4 Grand modèles de langage (Large Language Models)

Une piste prometteuse pour la prévision des fluctuations des taux d'intérêt réside dans l'utilisation de modèles de langage avancés tels que ChatGPT. Bien que ces modèles aient été initialement conçus pour générer du texte non structuré, l'introduction récente de la fonctionnalité de « structured outputs » offre la possibilité de produire des prévisions formatées et adaptées aux besoins spécifiques (OpenAI, N/A). Ces modèles, entraînés sur d'immenses corpus de données textuelles, possèdent des habiletés émergentes remarquables qui pourraient être mises à profit pour la prévision économique (Jason Wei, 2022). Cependant, nous n'avons pas exploré la précision des prévisions générées par ces modèles en raison d'une contrainte méthodologique importante. Il est actuellement impossible de limiter le corpus d'entraînement d'un modèle comme ChatGPT à des documents antérieurs à une date spécifique. Cette limitation empêche de recréer un environnement réaliste dans lequel le modèle ne disposerait que des informations disponibles au moment de la prévision. Toute tentative d'évaluation de ses prédictions serait donc inévitablement biaisée par l'accès du modèle à des données futures. Cette contrainte compromet la validité de l'analyse.



4.5 Comparaison des modèles

Modèle	Catégorie	Horizon de prévision							
		1 mois		3 mois		12 mois		36 mois	
		MAPE	MAE	MAPE	MAE	MAPE	MAE	MAPE	MAE
Naïf	Extrapolation	7.7%	0.146	18.23%	0.321	53.55%	0.909	84.38%	1.358
AR(12)	Extrapolation	7.63%	0.147	16.89%	0.304	52.66%	0.987	65.02%	1.420
VAR	Régression multiple multivariée	17.26%	0.236	38.7%	0.596	90.45%	1.616	57.17%	1.668
Lasso	Régression multiple univariée	7.40%	0.146	16.19%	0.308	43.20%	0.859	53.52%	1.273
N-HiTS	Non-paramétrique	7.19%	0.143	16.37%	0.319	44.78%	0.926	54.89%	1.444
TFT	Non-paramétrique	7.29%	0.144	16.05%	0.304	42.60%	0.791	52.98%	1.154

Le tableau ci-dessus affiche les mesures de performance obtenues sur la période couverte par l’ensemble de validation pour chaque modèle considéré. Nous utilisons celles-ci pour identifier le meilleur modèle. Les prévisions du modèle sélectionné seront utilisées pour formuler des recommandations quant à l’évolution attendue du taux d’intérêt pour la période à venir. Bien que les mesures de MAPE et MAE soient toutes deux pertinentes, nous privilégions le modèle obtenant le MAE le plus faible en cas de contradiction entre les deux mesures. Parmi les deux modèles de référence, le modèle naïf est celui ayant obtenu la meilleure performance avec un MAE de 0.146% pour l’horizon 1 mois. Cette performance est donc notre performance de référence. Le VAR est de loin le modèle obtenant la pire performance. Nous attribuons ceci au fait qu’il est le seul modèle multivarié parmi ceux considéré, c’est-à-dire qu’il cherche à modéliser l’évolution conjointe des variables explicatives et du taux, plutôt que seulement le taux.

Quant à lui, le modèle Lasso obtient une précision similaire à la référence pour l’horizon 1 mois, et il obtient une meilleure précision que la référence pour les autres horizons considérés. Nous remarquons que le gain de performance entre le modèle naïf et Lasso semble être proportionnel à l’horizon de la prévision, ce qui nous rassure quant à la pertinence des variables explicatives sélectionnées pour la génération de prévisions à long terme.

Les modèles d’apprentissage-profond, soient les modèles N-HiTS et TFT, sont ceux ayant obtenu la meilleure performance parmi ceux considérés. Pour les prévisions faites avec un horizon de 1 mois, le modèle N-HiTS a obtenu l’erreur la plus faible, avec une erreur moyenne de 0.143%. Pour les autres horizons, le *Temporal Fusion Transformer* a été le meilleur. Les différences de performance entre ces deux modèles sont relativement petites, mais nous sélectionnons le TFT comme modèle final, étant donné sa performance légèrement supérieure pour les horizons de plus d’un mois.

4.6 Performance sur l’ensemble de test

Horizon	MAPE	MAE
1 mois	5.16%	0.222
3 mois	10.18%	0.493
12 mois	18.21%	0.796
36 mois	108.64%	4.675

Le tableau ci-dessus présente la précision des prévisions produites par le modèle TFT pour la période couverte par l’ensemble de test, soit pour les 12 mois allant d’août 2023 à août 2024. Ces mesures représentent la performance espérée du modèle s’il était utilisé dans un contexte réel. Il faut cependant interpréter ces résultats avec prudence. Les erreurs affichées ne reflètent pas uniquement la qualité intrinsèque du modèle, mais dépendent également du niveau de volatilité observé durant la période étudiée. Une période marquée par des fluctuations inhabituelles ou une instabilité des taux



d'intérêt, par exemple la période pandémique de la COVID-19, peut entraîner de grandes erreurs, indépendamment des capacités prédictives du modèle. Cette nuance est essentielle pour une évaluation éclairée des performances.

5. Perspectives et recommandations

5.1 Analyse des Résultats : Prévisions

Les prévisions issues du modèle TFT montrent une baisse progressive du rendement des obligations à 10 ans du Trésor américain sur la période de janvier 2025 à juillet 2027. Partant d'un niveau initial de 4,23 % en août 2024 et allant à un niveau de 4,11 % en janvier 2025, le rendement diminue régulièrement pour atteindre environ 2,65 % en janvier 2027. Cependant, la tendance présente des caractéristiques distinctes selon les périodes analysées. Pour l'année 2025, la pente de la courbe reste relativement douce, avec une diminution graduelle des taux passant 4,11 % à 3,52 % en janvier 2026. Cette pente plus modérée peut refléter une transition progressive vers des conditions économiques plus stables, probablement liée à une atténuation des pressions inflationnistes et à des ajustements prudents de la politique monétaire.




Figure 8

Prévision de la variable cible pour un horizon futur de 36 mois. Les intervalles de prévision ont été exclus pour la clarté du visuel.

À partir de 2026, la pente s'accroît légèrement, indiquant une accélération de la baisse des rendements à long terme. Cette dynamique pourrait être interprétée comme un signal d'une économie approchant un nouvel équilibre, marqué par des anticipations d'inflation maîtrisées et une convergence des taux directeurs vers des niveaux plus accommodants. La chute plus rapide vers la fin de l'horizon prévisionnel pourrait également refléter une normalisation accélérée, en lien avec des ajustements structurels ou des attentes de croissance économique modérée.

5.2 Analyse des Impacts Dynamiques via SVAR

Pour mesurer les impacts des fluctuations des taux d'intérêt sur des métriques économiques globales, notre équipe a utilisé un modèle SVAR (Structural Vector Autoregressive). Ce modèle permet d'identifier les impacts d'un choc (augmentation unitaire) subi sur la variable cible. Le modèle SVAR est une extension du modèle VAR qui permet d'explorer les relations structurelles entre les variables. Dans un VAR classique, les innovations (erreurs de prévision ou résidus) sont corrélées de manière contemporaine (simultanée), ce qui empêche l'identification des relations causales. En d'autres mots, dans un VAR, un changement dans les innovations d'une variable peut être dû uniquement à un changement dans les innovations d'une autre variable ce que nous ne voulons pas. Le modèle SVAR résout ce problème en identifiant les chocs structurels (forces exogènes non corrélées entre elles) grâce à une décomposition de la matrice de corrélation des résidus du VAR, réalisée via la méthode de Cholesky (Moh, 2022). Par exemple, les chocs structurels de la politique monétaire ne



devraient pas être en réponse à d'autres chocs macroéconomiques. Un SVAR modélise donc la relation contemporaine entre les variables en supposant que les innovations sont exogènes.

Puisque notre objectif est de mesurer l'impact d'un changement du taux d'intérêt à un instant donné (t) sur les autres variables, nous avons établi des hypothèses spécifiques pour guider l'analyse. Les variables macroéconomiques utilisées ont été soigneusement sélectionnées en fonction de leur pertinence pour capturer les dynamiques clés. Nous avons choisi 6 variables (**Voir la figure 9**) qui selon nous, donne une image du panorama économique. Donc en analysant l'impact du choc unitaire sur notre variable cible, nous pouvons analyser l'impact de ce choc sur l'économie.

Avec le SVAR, nous avons pu estimer l'effet causal dynamique d'un choc unitaire sur le taux d'intérêt, représenté par la fonction de réponse impulsionnelle structurée (IRF) (Moh, 2022). Cette approche nous a permis d'analyser comment un choc structurel sur la variable cible influence les autres variables au fil du temps, fournissant des insights essentiels pour notre analyse.

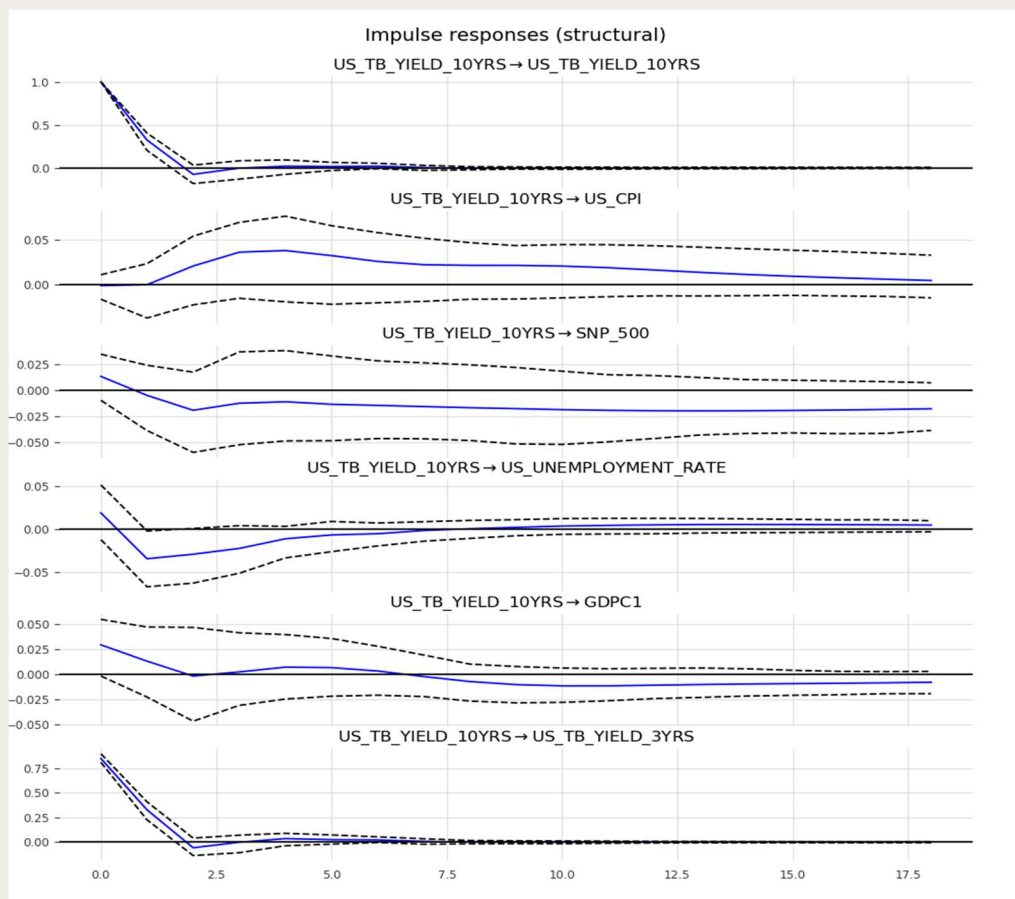


Figure 9

Prévision des réponses impulsionnelles (IRF) des variables du panorama économique à un choc structurel sur la variable cible sur un horizon de 18 mois

Les résultats du modèle SVAR mettent en évidence les réponses impulsionnelles des principales variables macroéconomiques à un choc unitaire sur le taux des obligations du Trésor américain à 10 ans (**US_TB_YIELD_10YRS**). Ces analyses permettent de visualiser les effets dynamiques et causaux de ce choc sur plusieurs indicateurs clés et sur un horizon temporel défini de 18 mois. On remarque que si la variable cible augmente de 1, ceci aura des effets sur toutes les variables que nous avons choisi. La prémisse est que toutes les variables partent à 0 et que seul un choc structurel (exogène) unitaire est appliqué à la variable cible. On observe ensuite les impacts de ce choc sur toutes les variables pendant un horizon de 18 mois. Après un certain délai (qui peut être plus que 18 mois), qui est différent pour chaque variable, l'effet du choc va se dissiper et la variable va retourner à l'origine (zéro). Le choc initial sur le rendement à 10 ans entraîne une réponse immédiate et transitoire sur ses propres valeurs, se stabilisant rapidement autour de zéro (après 3 mois).

Concernant l'indice des prix à la consommation (**US_CPI**), on remarque qu'il ne réagit pas immédiatement au choc, il prend environ 1 mois à réagir (il y a donc une propagation lente des chocs). Ceci est expliqué par le fait que les décisions



économiques peuvent prendre du temps à se propager sur la consommation, la production et sur les investissements, donc le CPI réagit avec un délai de 1 mois suite à une hausse unitaire du taux d'intérêt. Le CPI va augmenter quand la variable cible augmente cependant, l'augmentation sera de 0.04 au maximum 3 mois après le choc sur la variable cible. Une légère augmentation progressive est donc observée, reflétant une influence modérée des taux d'intérêt sur les pressions inflationnistes, possiblement via une contraction de la demande globale. Cet effet limité pourrait indiquer une inertie dans les mécanismes de transmission des politiques monétaires, particulièrement à long terme. Cette augmentation viendra se stabiliser un peu après l'horizon de 18 mois

Pour l'indice boursier S&P 500 (**SNP_500**), l'impact d'une hausse de la variable cible est positif (0.0125 immédiatement), mais cette hausse vient se dissiper rapide. Cette réponse peut être attribuée à la vulnérabilité de certains secteurs, comme les technologies ou l'immobilier, qui dépendent fortement des conditions de financement. Le S&P 500 semble se stabiliser à -0.02 même après l'horizon de 18 mois.

De même, le taux de chômage (**US_UNEMPLOYMENT_RATE**) enregistre une hausse modérée quand le choc survient, illustrant un ralentissement potentiel de l'activité économique provoqué par la hausse des taux. Cette hausse se dissipe rapidement et le taux de chômage diminue par la suite. Ce phénomène reflète l'effet des coûts d'emprunt accrus sur les investissements et la consommation des ménages. Le taux de chômage se stabilise après 7.5 mois.

En ce qui concerne le produit intérieur brut réel (**GDPC1**), l'effet est également positif au début (le GDPC1 devrait augmenter). Cette dynamique met en évidence les délais nécessaires avant que ces impacts ne soient pleinement ressentis dans l'économie réelle à très court terme. Bien que l'effet soit minime, ceci va contre nos attentes, nous nous attendions à une diminution immédiate du GDPC1. Une augmentation du taux d'intérêt devrait freiner la consommation et l'investissement et donc avoir un effet négatif sur le PIB brut réel. Il faudrait donc investiguer sur les effets réels de cet impact. En revanche, 6 mois après le choc, le PIB brut réel diminue ce qui vient confirmer notre hypothèse de base; les taux plus élevés devraient ralentir la croissance économique.

Enfin, la relation entre le rendement à 10 ans et celui à 3 ans (**US_TB_YIELD_3YRS**) démontre une transmission rapide et cohérente des variations de taux sur les segments de maturité plus courts. Ce phénomène souligne l'interconnexion structurelle des segments de la courbe des taux et leur ajustement aux changements des conditions de marché. L'effet est presque identique que celui le rendement à 10 ans, ce qui est tout à fait normal.

Bien entendu, si on appliquait un choc unitaire négatif (le taux d'intérêt diminue de 1), l'effet devrait être inverse sur chaque variables (on inverse les graphiques par rapport à l'axe des x). Il se pourrait que l'effet ne soit pas parfaitement symétrique; une baisse du taux d'intérêt pourrait avoir un impact moins prononcé sur le taux de chômage qu'une hausse du taux d'intérêt. Même si la magnitude de l'effet peut être différente, la direction sera inversée.

5.3 Recommandations Stratégiques

5.3.1 Marchés boursiers

La catégorie des marchés boursiers représente un actif net de 114 G\$. La forte performance récente a été principalement alimentée par les grandes entreprises technologiques et l'essor des secteurs liés à l'intelligence artificielle et à la transformation numérique, qui ont dominé les gains des indices globaux. (Caisse de dépôt et placement du Québec, 2023). Les prévisions de baisse des taux obligataires à long terme renforcent l'attractivité des secteurs sensibles au coût du capital, tels que la technologie et la consommation discrétionnaire. L'analyse des réponses impulsionnelles du modèle SVAR montre que le S&P 500 réagit positivement aux baisses des taux, soulignant une dynamique favorable pour les entreprises technologiques de croissance. Dans ce contexte, des titres comme Microsoft, Apple et Tesla se positionnent comme des opportunités clés, bénéficiant de solides fondamentaux et de tendances structurelles durables (Cicomasclo, 2024). Les entreprises de consommation discrétionnaire, telles qu'Amazon et LVMH, profitent également d'un regain de demande alimenté par des coûts de financement réduits (Rettino-Parazelli, 2024). Dans un contexte de volatilité persistante, comme en témoignent les fluctuations historiques des indices en 2022 et 2023, une gestion active et diversifiée reste essentielle. Les



secteurs défensifs, tels que la santé et les biens de consommation de base, offrent une résilience face aux cycles économiques et constituent une base solide pour atténuer les risques liés à la volatilité. De plus, l'intégration de stratégies ESG dans le portefeuille renforce la position de la CDPQ en tant que leader en investissement durable, tout en augmentant la robustesse du portefeuille face aux défis de marché (CFA Institute, 2023).

5.3.2 Infrastructure

La catégorie des infrastructures, représentant un actif net de 60 G\$. En 2023, ce portefeuille a généré un rendement solide de 9,6 %, avec une valeur ajoutée de 5,1 G\$, surpassant son indice de référence de 0,3 %. Cette performance a été portée par des investissements bien positionnés dans des secteurs essentiels comme l'énergie renouvelable, le transport ferroviaire et routier, ainsi que les infrastructures sociales et de télécommunications (Caisse de dépôt et placement du Québec, 2023). Une diminution des taux d'intérêt à long terme pourrait entraîner une baisse significative des coûts de financement, un facteur essentiel pour les projets d'infrastructure, souvent caractérisés par des besoins élevés en capitaux et des retours à long terme. Ce contexte économique crée un cadre favorable pour renforcer les investissements dans des actifs critiques alignés sur les tendances globales de transition énergétique et d'urbanisation (CFA Institute, 2023). Le portefeuille infrastructures de la CDPQ est particulièrement actif en Amérique du Nord, avec 17 % des investissements au Canada et 31 % aux États-Unis. Des projets comme la concession de l'autoroute 25 au Québec ou les participations dans des réseaux ferroviaires nord-américains illustrent cette stratégie, mettant en avant la capacité de la CDPQ à générer des flux de trésorerie stables grâce à des actifs bien établis. Ces investissements sont complétés par une diversification géographique mondiale, incluant des participations dans des centrales solaires au Japon et des réseaux électriques en Amérique latine (Caisse de dépôt et placement du Québec, 2023). Aux États-Unis, des villes au Texas, telles qu'Austin ou Dallas, offrent un fort potentiel pour des investissements en infrastructures numériques et énergétiques (Electric Reliability Council of Texas, 2023). Austin, avec sa croissance rapide et son positionnement comme hub technologique, pourrait bénéficier de micro-réseaux énergétiques ou de parcs solaires connectés à des infrastructures intelligentes (Singer, 2024). Un projet similaire au parc solaire Inuyama au Japon, déjà présent dans le portefeuille de la CDPQ, pourrait répondre à ces besoins tout en renforçant la diversification géographique et sectorielle (Caisse de dépôt et placement du Québec, 2023).

5.3.3 Immobilier

La catégorie immobilière, représentant un actif net de 45,6 G\$. Malgré un rendement annuel de -6,2 % en 2023, en raison des défis structurels du secteur. Ce rendement, bien qu'en baisse, a surpassé l'indice de référence de -10 %, reflétant une résilience accrue du portefeuille grâce à une allocation sectorielle et géographique stratégique (Caisse de dépôt et placement du Québec, 2023). Ce portefeuille se concentre principalement sur des secteurs porteurs tels que la logistique et le résidentiel, qui représentent désormais 27 % et 28 % de l'exposition. (Caisse de dépôt et placement du Québec, 2023). Ivanhoé Cambridge, bras immobilier de la CDPQ, a joué un rôle central dans cette stratégie, avec des projets emblématiques aux États-Unis et au Canada. La catégorie immobilière, représentant un actif net de 45,6 G\$. Malgré un rendement annuel de -6,2 % en 2023, en raison des défis structurels du secteur. Ce rendement, bien qu'en baisse, a surpassé l'indice de référence de -10 %, reflétant une résilience accrue du portefeuille grâce à une allocation sectorielle et géographique stratégique (Caisse de dépôt et placement du Québec, 2023). Ce portefeuille se concentre principalement sur des secteurs porteurs tels que la logistique et le résidentiel, qui représentent désormais 27 % et 28 % de l'exposition, au détriment des bureaux et des centres commerciaux, confrontés à une baisse de la demande liée au télétravail et au commerce électronique (Caisse de dépôt et placement du Québec, 2023). Ivanhoé Cambridge, bras immobilier de la CDPQ, a joué un rôle central dans cette stratégie, avec des projets emblématiques aux États-Unis et au Canada. Parmi ces projets, le complexe résidentiel Beckon en Caroline du Nord illustre une transition vers des actifs orientés vers les besoins résidentiels croissants dans des régions en expansion. Ce positionnement stratégique témoigne de la capacité de la CDPQ à identifier des marchés porteurs et à s'adapter aux changements structurels (Caisse de dépôt et placement du Québec, 2023). Dans cette optique, il pourrait être pertinent d'explorer des opportunités dans la région de Phoenix, en Arizona, qui connaît une forte croissance démographique, soutenue par un afflux migratoire interne et une économie diversifiée en plein essor (City Facts, 2024) (Countries Worldwide, 2024). Cette région, marquée par une demande croissante pour des complexes résidentiels multifamiliaux, offre un potentiel intéressant pour des projets similaires à Beckon en Caroline du Nord. En effet, Phoenix



attire des jeunes professionnels et des familles en quête de logements abordables, tout en bénéficiant d'un climat d'affaires favorable. La CDPQ pourrait tirer parti de cette dynamique pour développer des projets résidentiels intégrés, alignés sur les besoins locaux tout en profitant des coûts de financement réduit anticipés grâce à la baisse des taux d'intérêt (CFA Institute, 2023).

5.3.4 Revenu Fixe

Le portefeuille de revenu fixe de la CDPQ, représentant un actif net de 135 G\$, a enregistré un rendement annuel de 6,8 % en 2023, surpassant son indice de référence fixé à 6,6 %. Cette performance s'explique par la solidité des investissements en crédit privé et en obligations à rendement élevé, ainsi que par un positionnement opportun dans le crédit gouvernemental à long terme. Malgré les défis structurels liés à l'environnement de taux élevé au cours des dernières années (**Voir Section - 1**), le portefeuille a démontré une résilience notable, soutenue par des stratégies alignées sur les objectifs de rendement ajusté au risque (Caisse de dépôt et placement du Québec, 2023). Le portefeuille de revenu fixe de la CDPQ, représentant un actif net de 135 G\$, a enregistré un rendement annuel de 6,8 % en 2023, surpassant son indice de référence fixé à 6,6 %. Cette performance s'explique par la solidité des investissements en crédit privé et en obligations à rendement élevé, ainsi que par un positionnement opportun dans le crédit gouvernemental à long terme. Malgré les défis structurels liés à l'environnement de taux élevé au cours des dernières années (**Voir Section - 1**), le portefeuille a démontré une résilience notable, soutenue par des stratégies alignées sur les objectifs de rendement ajusté au risque (Caisse de dépôt et placement du Québec, 2023). Dans un environnement de baisse des taux d'intérêt anticipé par nos prévisions, les obligations à longue durée se distinguent comme une stratégie particulièrement avantageuse. Ces titres, caractérisés par une sensibilité accrue aux variations des taux (durée modifiée plus élevée), permettent de maximiser les gains en capital lorsque les taux baissent. Investir dans des obligations souveraines américaines à échéance longue, telles que les bons du trésor à 10 ou 30 ans, offrirait non seulement une opportunité d'appréciation de la valeur, mais renforcerait également la résilience du portefeuille dans des conditions de marché volatiles (CFA Institute, 2023). Les obligations à rendement élevé présentent également une autre opportunité stratégique. Bien que plus risquées, ces obligations bénéficient souvent d'une compression des écarts de crédit lorsque les taux baissent, ce qui accroît leur prix. En se positionnant sur des émetteurs solides dans des secteurs porteurs comme les infrastructures ou les énergies renouvelables, la CDPQ pourrait capturer des primes de rendement importantes tout en diversifiant davantage son portefeuille obligataire (CFA Institute, Charlottesville). De plus, des instruments financiers tels que les « swaps et futures », seraient également une opportunité afin de capitaliser lors d'une baisse d'intérêt. La vente d'un swap de taux d'intérêt (où l'on reçoit un taux fixe et paie un taux variable) ou l'achat d'un « future » permettrait de bénéficier de la différence positive entre le taux fixe reçu et le taux variable qui diminue, maximisant ainsi les rendements dans un contexte de détente monétaire.

6. Conclusion

En somme, ce rapport démontre que l'utilisation de modèles d'apprentissage profond, tels que le Temporal Fusion Transformer (TFT), permet de produire des prévisions significativement plus précises que les approches traditionnelles, tout en offrant des insights stratégiques pour la gestion des portefeuilles d'actifs. Malgré ces résultats prometteurs, la prévision des taux d'intérêt demeure une tâche complexe, influencée par de nombreux facteurs économiques et géopolitiques, souvent difficiles à modéliser avec exactitude. Nos analyses mettent également en lumière des opportunités d'amélioration. L'intégration de variables explicatives supplémentaires, combinée à une exploration plus approfondie des techniques de sélection de variables, pourrait renforcer la robustesse et la fiabilité des modèles. De plus, l'utilisation de méthodes avancées comme le SVAR pour simuler les impacts dynamiques des chocs économiques, ouvre des perspectives intéressantes pour une analyse plus complète des interrelations économiques. Enfin, les connaissances acquises dans le cadre de ce projet nous ont permis d'identifier de nombreuses pistes potentielles à explorer dans l'optique d'améliorer la performance des modèles proposés. Ces améliorations futures, telles que l'adoption de modèles hybrides combinant économétrie et apprentissage automatique, ou encore le développement de scénarios prospectifs plus sophistiqués, pourraient offrir des outils encore plus performants pour guider la prise de décision financière.



Annexe(s)

Annexe 1 – Variables Causales Considérées, par Catégorie

Catégorie	Variable	Identifiant	Description	Différenciée	Sélectionnée par Lasso
Décisions des Banques Centrales	Federal Funds Effective Rate	FFED	Taux auquel les banques se prêtent leurs réserves excédentaires à très court terme. Indicateur central de la politique monétaire de la Fed, il influence de nombreux taux d'intérêt dans l'économie.	X	
	Bank Credit, All Commercial Banks	TOTBKCR	Montant total des crédits accordés par toutes les banques commerciales, reflétant la disponibilité du financement dans l'économie.	X	
Anticipation inflation	University of Michigan: Inflation Expectation	MICH	Mesure les anticipations d'inflation des ménages américains, offrant un baromètre de la perception de l'évolution des prix et un indicateur clé pour la politique monétaire.		X
	10-Year Expected Inflation	EXPIN10YR	Mesure l'inflation anticipée sur une période de 10 ans, indicateur crucial pour la politique monétaire et la formation des taux d'intérêts à long terme.		X
Chômage / Emploi	Average Weekly Hours of Production and Nonsupervisory Employees (Manufacturing)	AWHMAN	Heures hebdomadaires moyennes des employés de production et non cadres dans le secteur manufacturier, indicateur précoce de l'évolution de l'emploi industriel.		
	Nonfarm Payroll Employment	PAYEMS	Nombre total d'emplois (hors secteur agricole), indicateur majeur de la dynamique du marché du travail et de la croissance économique.		


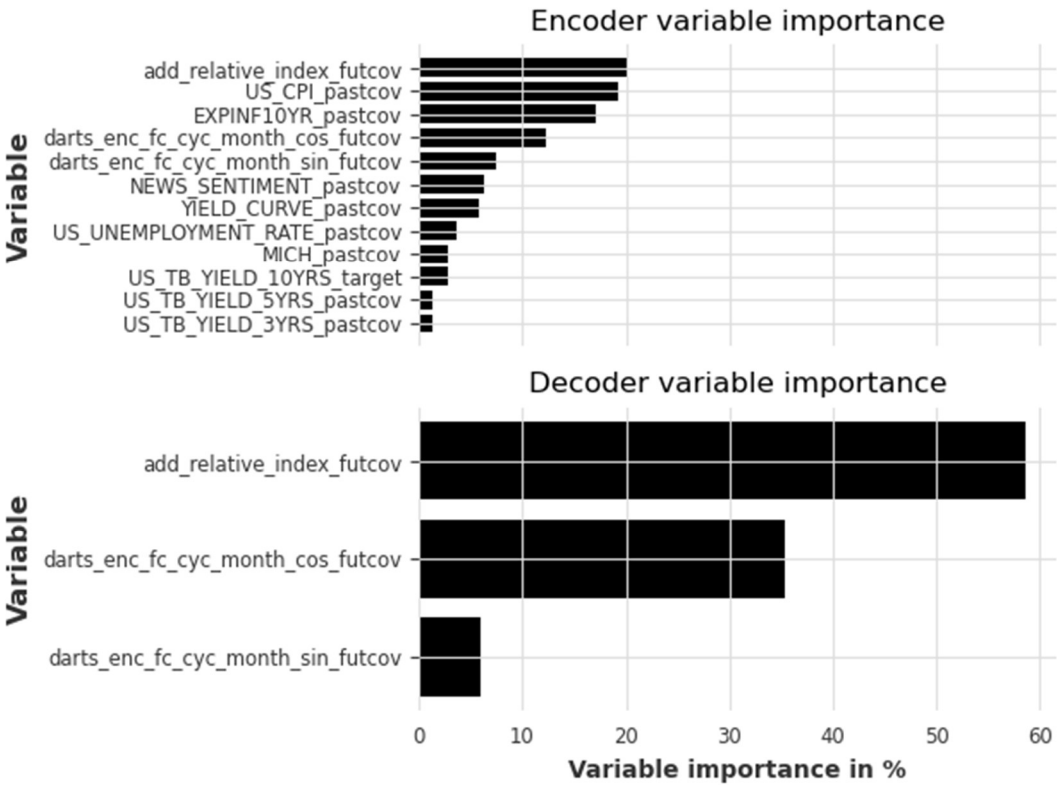
Catégorie	Variable	Identifiant	Description	Différenciée	Sélectionnée par Lasso
PIB	Real Gross Domestic Product	GDPC1	Mesure la valeur totale de la production de biens et services aux États-Unis, ajustée de l'inflation. Indicateur clé de la croissance économique réelle.	X	
	Gross Private Domestic investment	GPD1	Somme des investissements privés (entreprises et ménages), incluant l'investissement en capital fixe et les variations de stocks. Indicateur de la confiance économique et de la capacité productive future.	X	
Déficit Budgétaire gouvernemental	Government Total Expenditures	W068RCQ027SBEA	Dépenses publiques totales (fédérales, étatiques et locales), incluant achat de biens/services et transferts. Indicateur clé de la politique budgétaire et de son impact sur la croissance.	X	
Masse Monétaire	Small-Denomination Time Deposits: Total	STDSL	Montant total des dépôts à terme de faible valeur, reflétant la propension à l'épargne et la disponibilité de liquidités à moyen terme dans le système bancaire.		
Marchés Financiers	Taux US FED - 1 an	US_TB_YIELD_1YR	Rendement des bons du Trésor américain à 1 an, reflétant la perception du risque à court terme et les anticipations de politique monétaire.	X	
	Taux US FED - 3 an	US_TB_YIELD_3YRS	Rendement des bons du Trésor américain à 3 ans, reflétant les anticipations de marché à moyen terme et la perception du risque sur cette période.	X	X
	Taux US FED - 5 an	US_TB_YIELD_5YRS	Rendement des bons du Trésor américain à 5 ans, indiquant les anticipations de politique monétaire et d'inflation sur le moyen terme.	X	X



Catégorie	Variable	Identifiant	Description	Différenciée	Sélectionnée par Lasso
Marchés Financiers	Taux US FED - 3 Mois	US_TB_YIELD_3MTHS	Rendement des bons du Trésor américain à 3 mois, reflétant la perception du marché quant aux conditions monétaires de court terme.	X	
	Pente de la courbe des taux (10Y - 2Y)	YIELD_CURVE	Différence entre les taux d'intérêt à long terme et à court terme, baromètre essentiel des anticipations de croissance et de politique monétaire.		X
	S&P 500 (indice boursier)	SNP_500	Indice regroupant 500 grandes entreprises américaines, baromètre clé de la performance du marché boursier et de la confiance des investisseurs.	X	
Sentiment	Indice de sentiment financier (NLP Fed de San Francisco)	NEWS_SENTIMENT	Indice de sentiment dérivé du traitement automatique du langage (NLP) appliqué aux actualités économiques, offrant un baromètre supplémentaire de la perception du marché et des risques.	X	X



Annexe 2 – Graphiques d’interprétabilité du TFT



Bibliographie

- Abdul Fatir Ansari, L. S. (2024, Novembre 04). *Chronos: Learning the Language of Time Series*. Récupéré sur Arxiv: <https://arxiv.org/abs/2403.07815>
- Abhimanyu Das, W. K. (2024, April 17). *A decoder-only foundation model for time-series forecasting*. Récupéré sur Arxiv: <https://arxiv.org/abs/2310.10688>
- Britt, H. (2021, October 18). *A Timeline of the U.S.–China Trade War*. Récupéré sur Thomasnet: <https://www.thomasnet.com/insights/us-china-trade-war-timeline/>
- Bryan Lim, S. O. (2020, Septembre 27). *Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting*. Récupéré sur Arxiv: <https://arxiv.org/abs/1912.09363>
- Bureau of Industry and Security. (2024, December 2). *Commerce Strengthens Export Controls to Restrict China's Capability to Produce Advanced Semiconductors for Military Applications*. Récupéré sur Bureau of Industry and Security: <https://www.bis.gov/press-release/commerce-strengthens-export-controls-restrict-chinas-capability-produce-advanced>
- Caisse de dépôt et placement du Québec. (2023). *Rapport annuel 2023 – Conjuguer performance et progrès*. Montréal, Québec: CDPQ.
- CFA Institute. (2023). ESG Considerations in Portfolio Planning and Construction. Dans C. Institute, *Portfolio Management, Ethical and Professional Standards* (pp. 72 - 76). Charlottesville: CFA Institute.
- CFA Institute. (2023). GEOPOLITICAL RISK AND THE INVESTMENT PROCESS. Dans C. Institute, *Quantitative Methods, Economics* (pp. 526 - 536). Charlottesville: CFA Institute.
- CFA Institute. (2023). Interest Rate Risk and Return. Dans C. Institute, *Fixed Income* (pp. 235 - 260). Charlottesville: CFA Institute.
- CFA Institute. (2023). Investments in Private Capital: Equity and Debt. Dans C. Institute, *Derivatives, Alternative Investments* (pp. 299 - 318). Charlottesville: CFA Institute.
- CFA Institute. (2023). Real Estate and Infrastructure. Dans C. Institute, *Derivatives, Alternative Investments* (pp. 327-353). Charlottesville: CFA Institute.
- CFA Institute. (Charlottesville). Credit Risk. Dans C. Institute, *Fixed Income* (pp. 341 - 366). Charlottesville: CFA Institute.
- Chen, P. (2022, September 28). *Vector Error Correction Models with Stationary and Nonstationary Variables*. Récupéré sur Papers SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4218834
- Ciccomascolo, G. (2024). *Magnificent Seven Lead Wall Street Into 2025 With AI Driving Growth*. Récupéré sur CCN: <https://www.ccn.com/news/business/magnificent-seven-wall-street-ai-growth/>
- City Facts. (2024). *Phoenix (Arizona)*. Récupéré sur City Facts: <https://fr.city-facts.com/phoenix/population>
- City of Calgary. (2024). *Infrastructure Services reports*. Récupéré sur Calgary: <https://www.calgary.ca/our-strategy/infrastructure-reports.html>
- City of Edmonton. (2022). *District Energy*. Récupéré sur Gov Edmonton: https://www.gov.edmonton.ab.ca/projects_plans/district-energy

- Clark, D. (2022, May 17). *Wheat Price Spike Fuels Inflation*. Récupéré sur Investopedia: <https://www.investopedia.com/wheat-price-spike-fuels-inflation-5272396>
- Council of the European Union. (N/A). *EU sanctions against Russia explained*. Récupéré sur Council of the European Union: <https://www.consilium.europa.eu/en/policies/sanctions-against-russia-explained/>
- Countries Worldwide . (2024). *Villes américaines par population*. Récupéré sur Countries Worldwide: <https://countries-worldwide.com/fr/villes-americaines-par-population/>
- Country Economy. (2022, March). *Brent Crude Oil Prices (March 2022)*. Récupéré sur Country Economy: <https://countryeconomy.com/raw-materials/brent?dr=2022-03>
- Cristian Challu, K. G.-C. (2022, November 29). *N-HiTS: Neural Hierarchical Interpolation for Time Series Forecasting*. Récupéré sur Arxiv: <https://arxiv.org/abs/2201.12886>
- Dua, S. (2022, September 29). *Why a 2022 Housing Market Crash Could Be Worse Than 2008*. Récupéré sur InvestorPlace: <https://investorplace.com/2022/09/why-a-2022-housing-market-crash-could-be-worse-than-2008/>
- Electric Reliability Council of Texas. (2023). *Energy is Good for Texas*. Récupéré sur Comptroller Texas: <https://comptroller.texas.gov/economy/economic-data/energy/2023/ercot-snap.php>
- FasterCapital. (2024, June 04). *Modele de correction d erreurs vectorielles VECM cours de correction integration de VECM avec l autoregression vectorielle*. Récupéré sur FasterCapital: <https://fastercapital.com/fr/contenu/Modele-de-correction-d-erreurs-vectorielles---VECM---cours-de-correction---integration-de-VECM-avec-l-autoregression-vectorielle.html#Comprendre-la-coint-gration-et-la-correction-d-erreurs>
- Federal Bank of St. Louis. (2024). *FRED Economic Data*. Récupéré sur FRED St. Louis Fed: <https://fred.stlouisfed.org/>
- Federal Reserve Bank of San Fransisco. (2024). *Data and Indicators*. Récupéré sur FRBSF: <https://www.frbsf.org/research-and-insights/data-and-indicators/>
- Fletcher, R. (2024, March 27). *Alberta's population surged by record-setting 202,000 people. Here's where they all came from*. Récupéré sur CBC: <https://www.cbc.ca/news/canada/calgary/alberta-population-records-2023-to-2024-data-1.7157110>
- Forbes Advisor. (2023, September 27). *Fed Funds Rate History 1990 to 2023*. Récupéré sur Forbes: <https://www.forbes.com/advisor/investing/fed-funds-rate-history/>
- Goldman Sachs. (2024, November 8). *How Trump's Election Is Forecast to Affect US Stocks*. Récupéré sur Goldman Sachs: <https://www.goldmansachs.com/insights/articles/how-trumps-election-is-forecast-to-affect-us-stocks>
- Great Learning Editorial Team. (2024, October 15). *A Complete understanding of LASSO Regression*. Récupéré sur My Great Learning: <https://www.mygreatlearning.com/blog/understanding-of-lasso-regression/>
- Gregoire, E. (2023, September 21). *More Than 90% of North American Companies Have Relocated Production and Sourcing Over the Past Five Years*. Récupéré sur Boston Consulting Group: <https://www.bcg.com/press/21september2023-north-american-companies-have-relocated-production-sourcing-over-past-five-years>
- Hyndman, R. J. (2021). *Time series cross-validation*. In *Forecasting: Principles and Practice (3rd ed.)*. Monash University. Récupéré sur Otexts: <https://otexts.com/fpp3/tscv.html>



- International Labour Organization (ILO). (2020, December 8). *COVID-19 and the World of Work: Impact and Policy Responses*. Récupéré sur International Labour Organization: https://www.ilo.org/sites/default/files/wcmsp5/groups/public/%40dgreports/%40dcomm/documents/briefingnote/wcms_767028.pdf
- International Monetary Fund (IMF). (2020, May 20). *Tracking the \$9 Trillion Global Fiscal Support to Fight COVID-19*. Récupéré sur International Monetary Fund: <https://www.imf.org/en/Blogs/Articles/2020/05/20/tracking-the-9-trillion-global-fiscal-support-to-fight-covid-19>
- Jason Wei, Y. T. (2022, October 26). *Emergent Abilities of Large Language Models*. Récupéré sur Arxiv: <https://arxiv.org/abs/2206.07682>
- Jianjun Zhang, & J. J. (2023). *Granger Causality Test*. Récupéré sur ScienceDirect: <https://www.sciencedirect.com/topics/earth-and-planetary-sciences/granger-causality-test>
- John A. Miller, M. A. (2024, January 25). *A Survey of Deep Learning and Foundation Models for Time Series Forecasting*. Récupéré sur Arxiv: <https://arxiv.org/abs/2401.13912>
- Luca Donghi, C. C. (2022, January 26). *Forecasting macroeconomic variables with multi-variate time-series models*. Récupéré sur Medium: https://medium.com/@lucadonghi_25036/forecasting-macroeconomic-variables-with-multi-variate-time-series-models-afe13172ac40
- MacroTrends. (2024, January 07). *VIX Volatility Index - Historical Chart*. Récupéré sur macrotrends: <https://www.macrotrrends.net/2603/vix-volatility-index-historical-chart>
- Moh, F. X. (2022, March 19). *An Introduction to Structural Vector Autoregression (SVAR)*. Récupéré sur R-Econometrics: <https://www.r-econometrics.com/timeseries/svarintro/>
- Noble, J. (2024, June 12). *Qu'est-ce qu'un modèle autorégressif ?* Récupéré sur IBM: <https://www.ibm.com/fr-fr/topics/autoregressive-model>
- Ondo, J.-C. (2002). *Étude comparative des tests de stationnarité (Doctoral dissertation, Université du Québec)*. Récupéré sur Espace Inrs: <https://espace.inrs.ca/id/eprint/352/1/T000295.pdf>
- OpenAI. (N/A). *Structured Outputs*. Récupéré sur Platform OpenAI: <https://platform.openai.com/docs/guides/structured-outputs>
- Rettino-Parazelli, K. (2024, Octobre). *Consommation discrétionnaire: les clients sont de retour*. Récupéré sur Les Affaires: https://www.lesaffaires.com/mes-finances/consommation-discretionnaire-les-clients-sont-de-retour-edition_09_10_2024/
- Singer, T. (2024, November 12). *The Future of Tech Hubs: How Austin Can Lead in a New Era*. Récupéré sur Austin Technology Council: <https://www.austintechcouncil.org/tech-hub/>
- Statistiques Canada. (2022, February 09). *Les municipalités canadiennes avec les croissances et les décroissances les plus rapides de 2016 à 2021*. Récupéré sur StatCan: <https://www12.statcan.gc.ca/census-recensement/2021/as-sa/98-200-x/2021001/98-200-x2021001-fra.cfm>
- Trends, E. (2023, January 03). *Stocks Close Out 2022 With Worst Losses Since 2008*. Récupéré sur Nasdaq: <https://www.nasdaq.com/articles/stocks-close-out-2022-with-worst-losses-since-2008>
- U.S. Bureau of Labor Statistics. (2022, July 18). *Consumer prices up 9.1 percent over the year ended June 2022, largest increase in 40 years*. Récupéré sur U.S. Bureau of Labor Statistics:



<https://www.bls.gov/opub/ted/2022/consumer-prices-up-9-1-percent-over-the-year-ended-june-2022-largest-increase-in-40-years.htm>

UMVIE. (2023, June 27). *Taux à 10 ans : pourquoi ils sont importants pour l'économie*. Récupéré sur UMVIE: <https://umvie.com/taux-a-10-ans-pourquoi-ils-sont-importants-pour-leconomie/>

Wisniewski, S. (2024, November 29). *Markets News, November 29, 2024: S&P 500, Dow Hit Record Highs, Post Biggest Monthly Gains of 2024*. Récupéré sur Investopedia: <https://www.investopedia.com/dow-jones-today-11292024-8753278>

World Bank. (2020, June 8). *The Global Economic Outlook During the COVID-19 Pandemic: A Changed World*. Récupéré sur World Bank: <https://www.worldbank.org/en/news/feature/2020/06/08/the-global-economic-outlook-during-the-covid-19-pandemic-a-changed-world>

World Bank. (2021). *World Development Report (Chapter 5.1)*. Récupéré sur Global Value Chain in the Time of COVID-19(Coronavirus): <https://thedocs.worldbank.org/en/doc/c9af0143184de77cb58ddd5adf024508-0350012021/related/9781464816833-ch5-1.pdf>

Young, N. R. (2022, September 12). *Risk of Global Recession in 2023 Rises Amid Simultaneous Rate Hikes*. Récupéré sur World Bank: <https://www.worldbank.org/en/news/press-release/2022/09/15/risk-of-global-recession-in-2023-rises-amid-simultaneous-rate-hikes>

Zulauf, J. J. (2023, February 16). *The Russia-Ukraine War and Changes in Ukraine Corn and Wheat Supply: Impacts on Global Agricultural Markets*. Récupéré sur farmdoc daily: <https://farmdocdaily.illinois.edu/2023/02/the-russia-ukraine-war-and-changes-in-ukraine-corn-and-wheat-supply-impacts-on-global-agricultural-markets.html>

